

Notas sobre a modelagem da Copa do Mundo 2026

Ezequiel Braga

May 11, 2026

1 Resumo

Prever o resultado de uma partida de futebol é notoriamente difícil. Ao contrário de esportes com pontuações altas como o basquete, o futebol é um jogo de pontuação baixa onde um único desvio de sorte, um erro de arbitragem ou um momento de brilhantismo individual pode alterar completamente o resultado. Para dar conta dessa aleatoriedade inerente, usamos um motor estatístico sofisticado com o modelo de Dixon-Coles e o modelo de Poisson, e inferência Bayesiana, para calcular as *probabilidades* exatas de cada resultado possível.

Na base do nosso modelo está a ideia de que a verdadeira qualidade de uma equipe pode ser dividida em duas características mensuráveis: **Força de Ataque** e **Força de Defesa**. Quando duas equipes jogam, o modelo prevê o número de gols que cada uma marcará comparando o ataque de uma equipe com a defesa da outra. Se uma equipe com um ataque de elite joga contra uma equipe com uma defesa vulnerável, o modelo inclina fortemente as probabilidades para uma alta contagem de gols. Além disso, o modelo aplica um efeito médio a ambas as equipes.

Para os modelos, consideramos duas famílias: o modelo de **Poisson**, que assume que os gols do time da casa e os gols do time visitante são eventos de Poisson independentes; e o modelo de **Dixon-Coles**, que implementa a correção de Dixon-Coles informando ao computador que os gols são dependentes do estado atual da partida e fornecendo mais precisão na previsão de placares baixos.

Para garantir que o modelo reflita a realidade atual, aplicamos um **Filtro Temporal e Decaimento Exponencial**. Restringimos nossos dados aos últimos quatro anos, mas, mais importante, aplicamos uma escala de importância decrescente. Uma partida jogada ontem retém 100% do seu peso estatístico. À medida que recuamos no tempo, a importância de partidas mais antigas desaparece gradualmente.

Além disso, aplicamos um **Peso do Torneio**. Uma equipe pode testar novos jogadores em um amistoso internacional, levando a resultados inesperados. Nosso modelo reconhece que partidas competitivas — como as eliminatórias da Copa do Mundo ou campeonatos continentais (por exemplo, a Eurocopa ou a Copa América) — são reflexos mais fiéis da habilidade de uma equipe. Essas partidas recebem maior importância matemática com base nas regras oficiais da FIFA.

Para fazer inferências, usamos um esquema **Bayesiano**. Para as simulações, usamos **Monte Carlo**. Programamos as regras exatas da Copa do Mundo no computador — incluindo o sistema de pontos da fase de grupos e os critérios de desempate. Então, pedimos ao computador para simular o torneio inteiro, desde a primeira partida até a final. Repetimos essa simulação 10.000 vezes. Para partidas da fase eliminatória que terminam em empate, o modelo as resolve como um cara ou coroa literal de 50/50. Analisando os resultados agregados desses 10.000 torneios paralelos, podemos calcular a chance percentual exata de cada equipe chegar a uma determinada fase.

Com esses resultados, selecionamos o melhor modelo com base no desempenho preditivo nas duas últimas Copas do Mundo.

2 Preparação dos Dados

Antes de ajustar o modelo, aplicamos dois filtros:

- Filtro temporal: selecionamos as partidas dos últimos quatro anos;
- Filtro de equipe: selecionamos equipes com mais de 20 partidas.

Para cada partida $m \in \mathcal{M}$, definimos também um peso de jogo, ω_m , que é o produto de outros

dois pesos:

- Peso temporal: $\exp(-\alpha t)$, para $\alpha = 0.001$ (decaimento exponencial);
- Peso do torneio: calculado de acordo com as regras da FIFA.

3 Modelos

3.1 Modelo de Poisson

Para uma partida $m \in \mathcal{M}$ com gols do time da casa $G_{hm} \in G_h$ e gols do time visitante $G_{am} \in G_a$, consideramos $G_{hm} \perp G_{am}$ e

$$\begin{aligned} G_{hm} | \lambda_{hm} &\sim \text{Poisson}(\lambda_{hm}), \\ G_{am} | \lambda_{am} &\sim \text{Poisson}(\lambda_{am}), \end{aligned}$$

com

$$\begin{aligned} \log(\lambda_{hm}) &= \alpha_{hm} + \beta_{hm} + \eta \\ \log(\lambda_{am}) &= \delta_{am} + \gamma_{am} + \eta, \end{aligned}$$

onde α_{hm} é a habilidade de ataque do time da casa; β_{hm} é a habilidade de defesa do time visitante; δ_{am} é a habilidade de ataque do time visitante; γ_{am} é a habilidade de defesa do time da casa; e η é um efeito comum. Para uma partida $m \in \mathcal{M}$, seja $x = g_{hm}$ e $y = g_{am}$. A probabilidade conjunta de o time da casa marcar x gols e o time visitante marcar y gols é:

$$P(X = x, Y = y) = \frac{\lambda_{hm}^x \exp(-\lambda_{hm})}{x!} \frac{\lambda_{am}^y \exp(-\lambda_{am})}{y!},$$

3.2 Modelo de Dixon-Coles

Para levar em conta a dependência entre os gols do time da casa e do time visitante em partidas de pontuação baixa, o modelo de Poisson independente é modificado pela introdução de um parâmetro de dependência, ρ . Para uma partida $m \in \mathcal{M}$, seja $x = g_{hm}$ e $y = g_{am}$. A probabilidade conjunta de o time da casa marcar x gols e o time visitante marcar y gols é:

$$P(X = x, Y = y) = \tau_{\lambda, \mu}(x, y) \frac{\lambda_{hm}^x \exp(-\lambda_{hm})}{x!} \frac{\lambda_{am}^y \exp(-\lambda_{am})}{y!},$$

com as taxas de pontuação definidas como:

$$\begin{aligned} \log(\lambda_{hm}) &= \alpha_{hm} + \beta_{hm} + \eta \\ \log(\lambda_{am}) &= \delta_{am} + \gamma_{am} + \eta, \end{aligned}$$

e onde a função de dependência $\tau(x, y)$ é definida como:

$$\tau_{\lambda, \mu}(x, y) = \begin{cases} 1 - \lambda_{hm} \lambda_{am} \rho & \text{se } x = 0, y = 0 \\ 1 + \lambda_{hm} \rho & \text{se } x = 0, y = 1 \\ 1 + \lambda_{am} \rho & \text{se } x = 1, y = 0 \\ 1 - \rho & \text{se } x = 1, y = 1 \\ 1 & \text{caso contrário.} \end{cases}$$

3.3 Não-identificabilidade

Como $\mathcal{L}(\alpha + c, \beta - c, \delta + c, \gamma - c, \eta; G_h, G_a) = \mathcal{L}(\alpha, \beta, \delta, \gamma, \eta; G_h, G_a)$, o modelo é não-identificável. Para resolver isso, se temos n clubes, podemos definir $\alpha_n = \sum_{i=1}^{n-1} \alpha_i$, $\beta_n = \sum_{i=1}^{n-1} \beta_i$, $\delta_n = \sum_{i=1}^{n-1} \delta_i$ e $\gamma_n = \sum_{i=1}^{n-1} \gamma_i$ (o mesmo ocorre com o modelo de Dixon-Coles).

3.4 Verossimilhança

Para $\theta = (\alpha, \beta, \delta, \gamma, \eta)$ ou $\theta = (\alpha, \beta, \delta, \gamma, \eta, \rho)$, temos a log-verossimilhança

$$\mathcal{L}(\theta; G_h, G_a) = \sum_{m \in \mathcal{M}} \omega_m \ln(P(G_{hm} = g_{hm}, G_{am} = g_{am})).$$

3.5 Inferência

Para fazer inferências, definimos distribuições a priori e usamos um esquema Bayesiano. Suponha que definimos uma priori conjunta para θ , $\pi(\theta)$, então podemos calcular a distribuição a posteriori

$$p(\theta|G_h, G_a) = \frac{\mathcal{L}(\theta; G_h, G_a)\pi(\theta)}{\int \mathcal{L}(x; G_h, G_a)\pi(x)dx}.$$

4 Seleção de Modelo


Para cada modelo, definimos uma combinação de prioris da seguinte forma:

- Prioris normais para as forças de ataque e defesa;
- Prioris t-Student para as forças de ataque e defesa;
- Prioris de ataque incluem `prior_strength` a partir dos dados do ranking da FIFA;
- Prioris de ataque são centradas em zero.

Também usamos uma abordagem hierárquica, onde definimos uma priori de Cauchy para as variâncias. Para os demais parâmetros, definimos uma priori normal. Isso resulta em um conjunto de oito modelos para comparar. Para isso, usamos um desempenho preditivo baseado nas duas últimas Copas do Mundo. Avaliamos a qualidade preditiva usando uma regra de pontuação, orientada negativamente (valores menores indicam melhores previsões). Seja n o número de partidas avaliadas. Para cada partida t , seja $\mathbf{z}_t = (z_{H,t}, z_{D,t}, z_{A,t})$ o vetor de resultado codificado em one-hot, onde H , D e A denotam vitória do time da casa, empate e vitória do time visitante, respectivamente. Seja $\mathbf{p}_t = (p_{H,t}, p_{D,t}, p_{A,t})$ as probabilidades previstas correspondentes. O **Brier Score** (BS) mede a precisão das previsões probabilísticas para resultados categóricos, calculado como o erro quadrático médio entre as probabilidades previstas e os resultados observados:

$$BS = \frac{1}{n} \sum_{t=1}^n \sum_{j \in \{H,D,A\}} (z_{j,t} - p_{j,t})^2.$$

Com base em sua distribuição a posteriori, realizamos uma seleção de modelo como na Figura 1.



(a) BCI do Brier Score para a Copa do Mundo de 2018.

(b) BCI do Brier Score para a Copa do Mundo de 2022.

Figure 1: Comparação de modelos.

Podemos ver que não temos uma diferença significativa entre os modelos, mas escolhemos o primeiro modelo para fazer as previsões (Poisson com priori normal e ranking).

5 Simulações

Para calcular probabilidades relevantes, usamos simulação de Monte Carlo com as respectivas restrições para a chave do torneio. Para a fase eliminatória, se ocorrer um empate, uma equipe avança com probabilidade de 0.5. Também calculamos 10.000 amostras.